Semantic Web Integration of Empirical Thesis Metadata

Grigoris Markakis-MTP 329 ,
Maria Katsamani-MTP 361, George Mpitzes-MTP 337

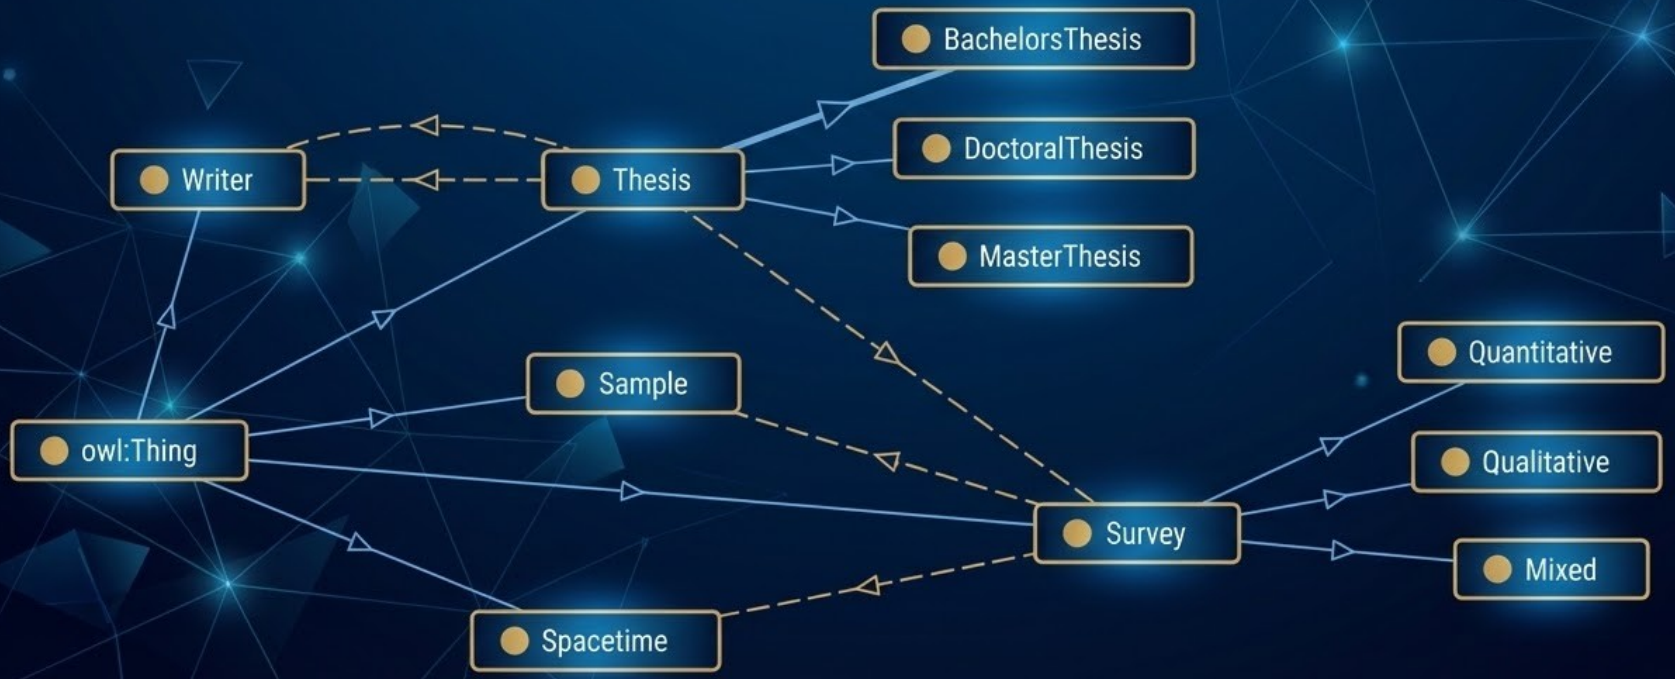

Dark Data

- **The Issue:** Valuable empirical data in theses is often “hidden” in university repositories.
- **Why?** Current systems use simple standards like Dublin Core that can’t describe specific research details like methodology or sample size.
- **Impact:** This research exists but is nearly impossible for others to find or reuse.

Our Solution – The Semantic Approach

The Goal

Transform flat XML data into a formal OWL ontology.

The Innovation

Building a **Knowledge Graph** that understands the *context* of research, not just the text.

Metadata Strategy

A “hybrid” model combining the simplicity of Dublin Core with the depth of DDI.

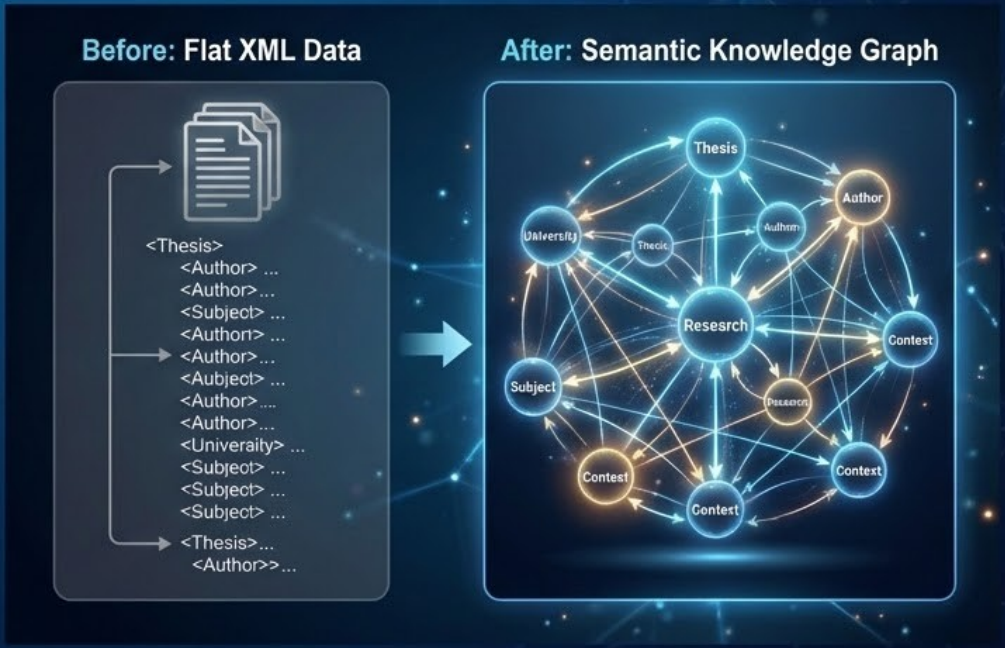

Ontology Design – The "Living Map"

- **Core Structure:** Five primary disjoint classes: Thesis, Writer, Survey, Sample, and Spacetime .
- **Intelligence:** Thesis -Bachelors, Master, Doctoral and Survey -Qualitative, Quantitative, Mixed .
- **Connective Tissue:** Object properties (e.g., `hasWriter`, `hasSurvey`) create the logical relationships a computer can follow .

33 Local Fields → **International Standards** (Schema.org, Dublin Core Terms)

Mapping local data for global compatibility

Dual-Language Support (rdfs:label): English & Greek

Benefit: Globally compatible, machine-readable, and interconnected data.

The AI Pipeline – Automated Data Extraction

PDFs of Theses

Python/Gemini
(gemini-3-flash)

Structured Data
(CSV/Turtle .ttl)

RDF Triples
Virtuoso Universal Server
(SPARQL endpoint)

The Challenge: Manually entering data for 31 theses is time-consuming.

The Tech: A Python program using **Google Gemini** (gemini-3-flash) to analyze PDFs.

Outcome: Accurate extraction of 42 specific fields into structured CSV and then Turtle (.ttl) files.

Storage: Data is hosted in a **Virtuoso Universal Server** acting as a SPARQL endpoint

System Architecture

- **Web Framework**: Built with **Python and Flask** using the MVC model.
- **Data Access**: Uses **SPARQLWrapper** to “talk” to Virtuoso and retrieve results.
  - The ontology remains independent of the UI.
  - SPARQL logic is encapsulated in the backend.
  - The frontend is responsible solely for visualization and interaction.
  - This design eliminates the need for additional backend requests.
  - It avoids re-executing SPARQL queries.
  - Finally, it enables query-independent record inspection.

Διαχείριση Ακαδημαϊκών Διατριβών

Διάλεξε ενέργεια/ερώτημα, κάνε φιλτράρισμα και δες αποτελέσματα. Η σχεδίαση είναι "one-stop dashboard" για τα SPARQL ερωτήματα.

Virtuoso + SPARQL

Semantic Repository

Fast Filters

ΒΑΣΙΚΕΣ ΑΝΑΣΗΤΗΣΕΙΣ

Title & Keywords Search

Αναζήτηση με Λέξεις (Τίτλος & λέξεις-κλειδιά)

Τίτλος & Keywords

Εύρεση

Abstract Search

Αναζήτηση στην Περιληψη (abstract)

Περίληψη...

Εύρεση

Υποστηρίζεται αναζήτηση χωρίς τόνους.

Writer Search

Αναζήτηση Συγγραφέα

Ονομα η Γινιόνομα

Αναζήτηση

Υνοσειιμίζεινα αναζήτηση γιωις, τόνους και με διααρυμεική ουμα ονόματος.

Supervisor Search

Αναζήτηση Επιβλέποντα

Οναμα Γ πιβλέποντα

Εύρεση Διατριβών

Βρες διατριβές με βάση τον/την επιβλέπονταλιγαα.

Filter Categories

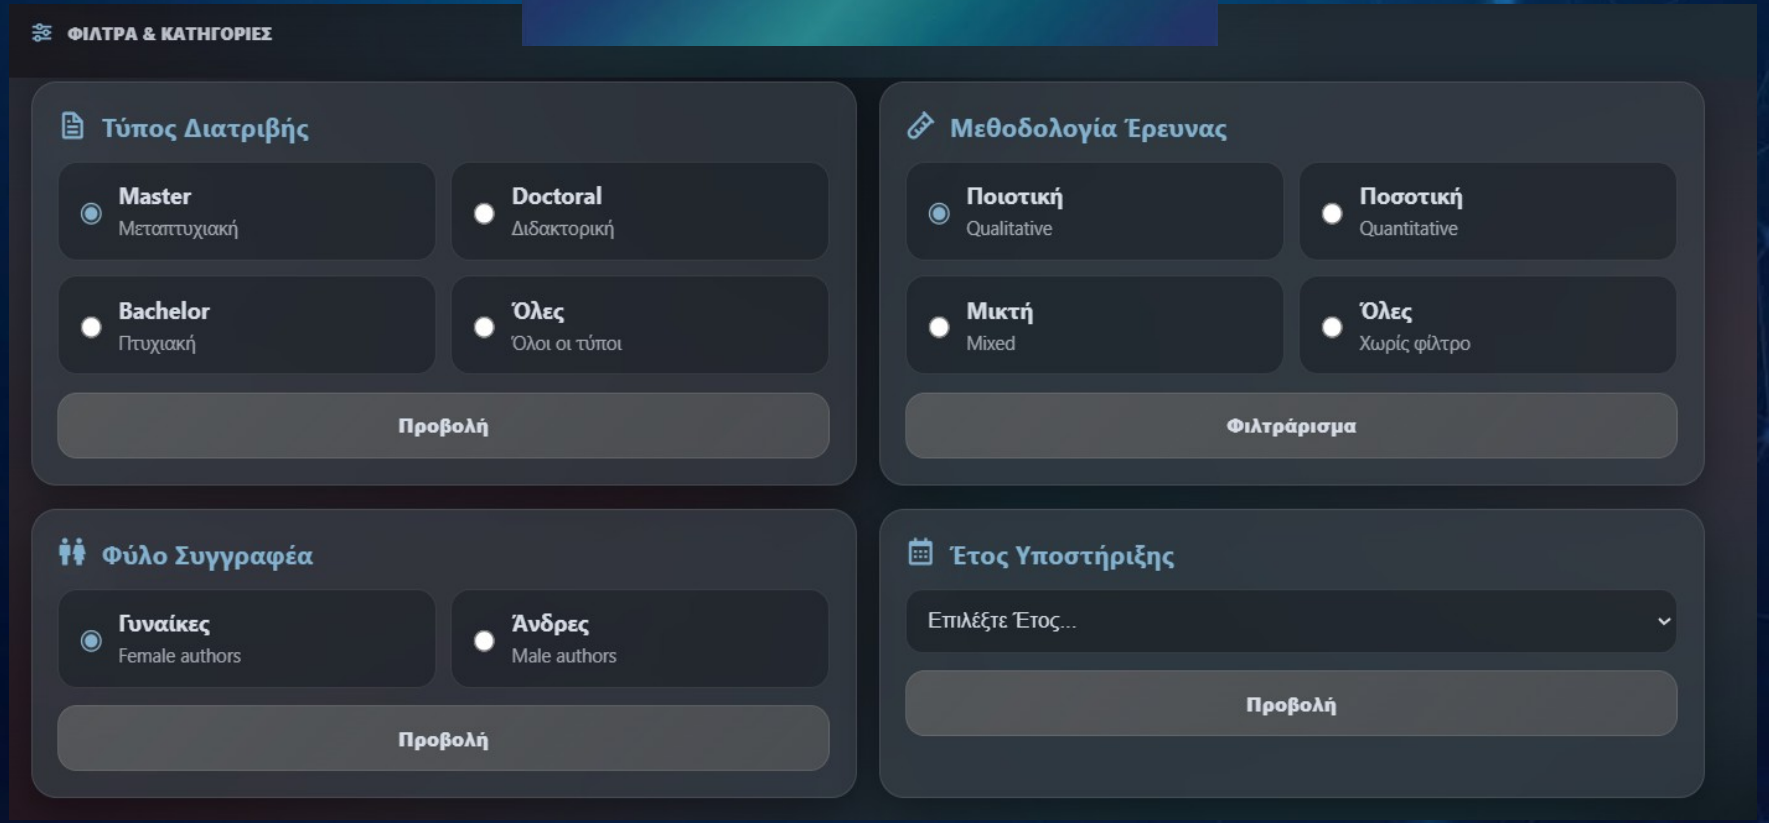

Αποτελέσματα Ερωτήματος

Πατήστε "Προβολή" για popup με λεπτομέρειες (thesis_details).

← Πίσω | Εκτύπωση / PDF

Title	Abstract	SurName	FirstName	DateOfSupport	Ενέργειες
«Εσωτερικός Έλεγχος στην Εθνική Τράπεζα Ελλάδος»	Οι σύγχρονες κοινωνίες και οικονομίες καθιστούν αναγκαία την ύπαρξη συγκεκριμένων νομοθετικ...	Κοΐμτζής	Εμμανουήλ	2021-04-17	Προβολή
HUMANITARIAN LOGISTICS – Η ΠΕΡΙΠΤΩΣΗ ΤΗΣ ΒΙΑΛ ΣΤΗ ΧΙΟ	Η συγκεκριμένη εργασία έχει σαν σκοπό να αναδείξει ακριβώς το σύστημα διαχείρισης των...	Δανού	Βασιλική	2021-03-22	Προβολή
«ΑΦΟΡΑ ΤΟ ΣΥΝΟΛΟ ΤΗΣ ΚΟΙΝΩΝΙΑΣ ΚΑΙ ΟΧΙ ΜΟΝΟ ΤΟ ΧΩΡΟ ΤΟΥ ΣΧΟΛΕΙΟΥ»: ΑΠΟΨΕΙΣ...	Βασικό χαρακτηριστικό των εκπαιδευτικών συστημάτων του 21ου αιώνα σε παγκόσμιο,...	Κουδουνά	Παναγιώτα	2021-01-01	Προβολή
Η ΣΥΜΒΟΛΗ ΤΗΣ ΠΟΙΟΤΗΤΑΣ ΥΠΗΡΕΣΙΩΝ ΚΑΙ ΕΞΥΠΗΡΕΤΗΣΗΣ ΠΕΛΑΤΩΝ ΣΤΗΝ ΕΛΛΗΝΙΚΗ...	Ο στόχος της συγκεκριμένης διπλωματικής εργασίας είναι να παρουσιάσει τη διοίκηση και το...	Φλωροκάπη	Στεργιανή	2020-03-31	Προβολή

search 'Abstract Field' with the word 'ΣΥΣΤΗΜΑ'

Πλήρης Προβολή

Στοιχεία από thesis_details.

Detailed view of a specific thesis, displaying comprehensive metadata.

Κλείσιμο

ABSTRACT

Στην εργασία αυτή εξετάζεται το ζήτημα του προσφυγικού – μεταναστευτικού εστιάζοντας στην αγορά εργασίας και στην ένταξη τους σε αυτήν. Οι διαδικασίες ένταξης και ενσωμάτωσης των προσφύγων-μεταναστών στις κοινωνίες υποδοχής είναι αντικείμενο μελέτης από αρκετούς ερευνητές όπου κάθε ερευνητής ανάλογα με το αντικείμενο της έρευνας του δίνει έναν διαφορετικό ορισμό στις έννοιες αυτές.

BASICUNIT

πρόσφυγες-μετανάστες

COLLECTIONMETHOD

σκόπιμης δειγματοληψίας και της δειγματοληψίας της χιονοστιβάδας

DATEOFSUPPORT

2023-06-01

DEPARTMENT

Τμήμα Κοινωνιολογίας

FIRSTNAME

Ουρανία

GENDER

Γυναίκα

GEOGRAPHICALUNIT

Μυτιλήνη

HASSAMPLE

HASSURVEY

Live Aggregates: Real-time stats on gender distribution and support years .

Visualization: Interactive Bar and Doughnut charts powered by **Chart.js** .

Automated Insights: The UI automatically computes peak production years and gender percentages.

Conclusion & Future Impact

Goal Met:

We proved student research doesn’t have to stay “dark data”.

The Result:

A scalable framework that turns individual academic projects into a collective, accessible body of knowledge.

Next Steps:

Elevating Gray Literature to the status of Linked Open Data.

Thank you!

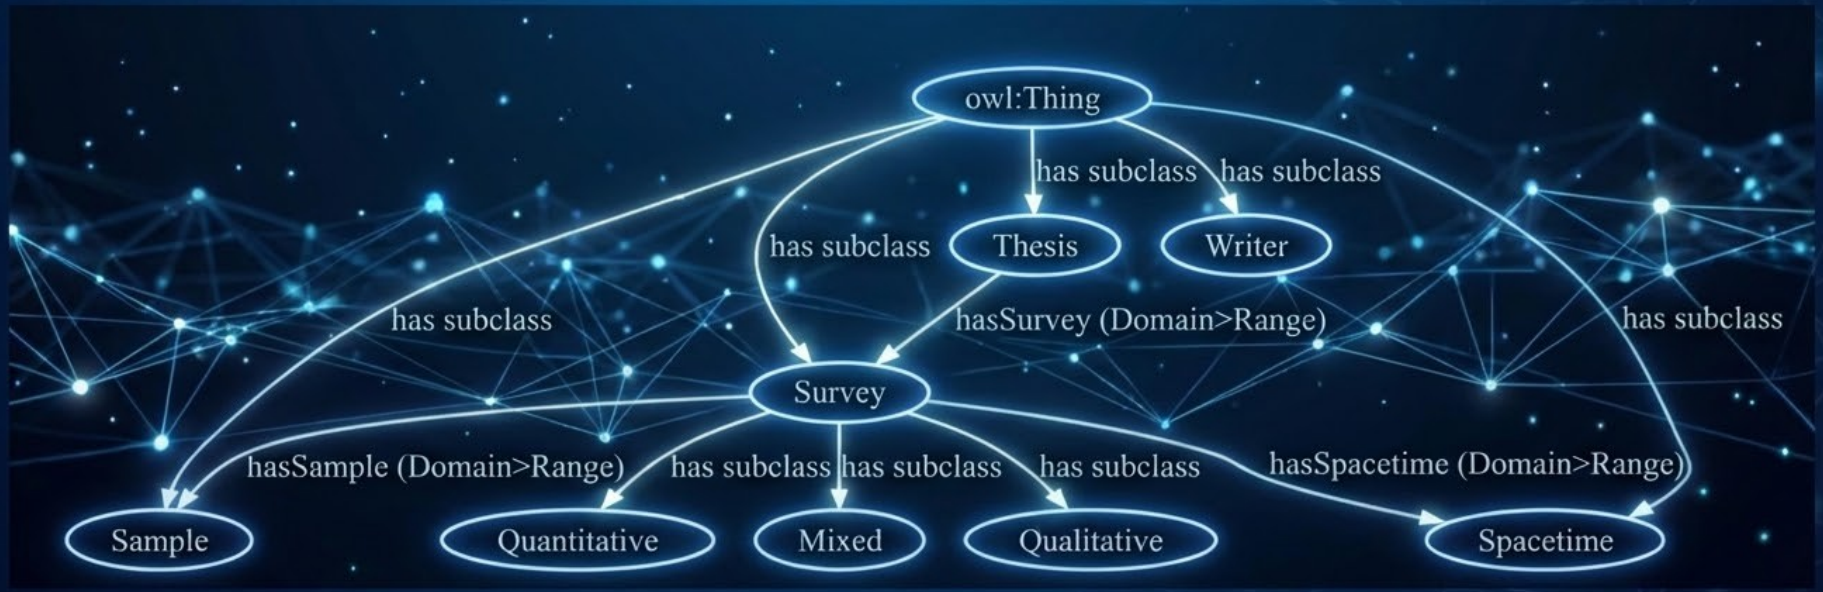

Based on the paper “ Enhancing Discoverability: A Metadata Framework for Empirical Research in Theses”